

Amadeus: 世界线观测与推演型 Agent-RAG 智能体

角色化智能体 · 检索增强生成 · 反事实推演 · 多模态交互

项目作者: 陆泽熙

当前阶段: Phase 2 - Worldline RAG

更新日期: 2026.09.20

把资料变成世界线档案，把关键选择变成可检索、可解释、可继续探索的分歧点。

1. 项目概述

项目名称: Amadeus: 世界线观测与推演型 Agent-RAG 智能体

一句话定位: 把用户上传的历史、科学、动漫设定或原创人物经历作为“世界线档案”，由角色化 Agent 检索证据、识别分歧点，并生成可解释的因果推演或沉浸式分支叙事。

Amadeus 以《命运石之门》中“数字化人格”的概念为灵感，采用 **FastAPI + Vue 3 + LangGraph + LangChain + ChromaDB + GPT-SoVITS** 构建。它既可以进行自然对话、调用工具和管理个人知识库，也可以围绕“如果某个关键事件没有发生，之后会怎样”这一类问题进行世界线推演。

项目的核心不再只是“让模型扮演一个角色”，而是将以下能力组合为完整应用：

- Agent:** 理解意图并自主调用时间、计算、知识库、网页、邮件等工具。
- RAG:** 从用户上传的资料中检索与当前分歧点有关的事实和设定。
- 世界线引擎:** 把原始进程、分歧点、约束条件和连锁影响组织成推演。
- 角色化交互:** 以 Amadeus 人格、视觉工作台和角色语音呈现结果。
- 工程化前后端:** 提供流式响应、文件管理、状态面板、会话记忆和异常恢复。

2. 项目背景与问题

通用大模型可以直接回答反事实问题，但它通常存在三个问题：

- 参考基线不稳定:** 模型可能混淆史实、作品设定和网络二创。
- 推演过程不可控:** 答案容易只给一个“听起来合理”的结论，缺少分歧点和因果链。
- 私有设定不可知:** 原创人物经历、班级案例或用户自己编写的世界观不在模型参数中。

本项目使用 RAG 保存“原始世界线资料”，在回答前检索相关片段，再由 Agent 结合提示词规则进行推演。RAG 的作用不只是规范语气，而是给模型提供一份可更新、可替换、可追溯的推演依据。

例如，用户上传“林默的成长经历”后，可以设置“初二时家人同意参加艺考”为分歧点。系统先检索原始经历和人物约束，再分别分析学业路径、家庭关系、经济压力、专业训练和心理状态可能产生的变化，而不是凭空替人物编写一段固定结局。

3. 核心体验：双模式世界线推演

3.1 观测模式

观测模式面向理性分析，适合历史事件、科学史、作品剧情和个人发展路径。

- 用户设置分歧点
 - Agent 强制检索知识库
 - 还原原始世界线与已知约束
 - 区分事实、资料缺口与合理假设
 - 分析直接影响、二阶影响和长期影响
 - 输出候选世界线及不确定性

观测模式不会提升或降低模型本身的“精度档位”。它改变的是任务提示词、检索要求和输出结构，使模型优先做证据约束下的因果分析。

3.2 沉浸模式

沉浸模式面向情境体验。在检索相同背景资料后，系统以场景、行动和对话讲述另一条世界线，并在结尾说明关键变化和下一个可继续选择的分歧点。

- 知识检索
 - 人物与时代约束
 - 场景化叙事
 - 世界线变动率提示
 - 关键变化回收
 - 下一分歧点

对比项	观测模式	沉浸模式
目标	分析“为什么会变化”	体验“变化后的世界”
表达	因果链、约束、不确定性	场景、行动、对白
适用	汇报、研究、讨论、教学	故事体验、角色互动、创作
RAG	必须先检索	必须先检索
模型能力	相同	相同

4. 知识库设计

4.1 当前示例资料

项目已经准备并可上传以下类型的世界线资料：

- 世界线推演方法与使用说明
- 《命运石之门》世界线规则、关键事件时间线、人物与动机
- 牛顿与经典力学、爱因斯坦与相对论、图灵与计算机发展
- 原创人物“林默”的艺考分支世界线

这些文件证明知识库不仅能存教材和公司文档，也能存储“人物历史进程 + 已知约束 + 关键节点 + 可选分支”。

4.2 文档入库流程

```
上传 PDF / DOCX / TXT / MD / CSV / JSON
→ 计算 MD5 并去重
→ 提取文本
→ 递归切分为知识片段
→ BGE 中文向量化
→ 写入 ChromaDB
→ SQLite 记录文件元数据
```

4.3 两条 RAG 链路

标准 RAG 问答：用户在知识库面板直接提问，系统检索片段并返回答案和来源，适合资料核对与实训验收。

Agent-RAG 对话：用户在主对话区发问，LangGraph Agent 自主决定调用 `search_knowledge_base`，再以角色语气组织结果，适合自然对话和世界线推演。

5. 系统架构

```
Vue 3 角色工作台
├─ 知识库：上传、列表、删除、RAG 问答
├─ 角色舞台：立绘、状态、音频响应、Live2D 预留
├─ 对话控制台：SSE 文本、工具事件、双模式开关
└─ 系统监视器：会话、工具、知识片段、角色状态
    |
    ▼
FastAPI API / WebSocket
├─ LangGraph ReAct Agent
│   ├── DeepSeek / Qwen
│   ├── 工具决策与执行
│   ├── AsyncSqliteSaver 会话记忆
│   └─ 中断工具历史自动修复
├─ RAG 服务
│   ├── KnowledgeBaseService
│   ├── VectorStoreService
│   └─ RagService (Prompt + LCEL + Parser)
└─ 语音服务
    ├── FunASR 中文语音识别
    ├── 中文到日文翻译
    └─ GPT-SoVITS 角色语音合成
```

6. 技术栈

模块	技术选型	作用
前端	Vue 3 + Vite	三栏角色工作台和响应式交互
后端	FastAPI	REST、SSE 和 WebSocket 接口
Agent	LangGraph <code>create_react_agent</code>	ReAct 决策、工具调用与状态流转
RAG	LangChain LCEL	Prompt、检索上下文和输出解析
LLM	DeepSeek / Qwen	对话生成、工具决策和推演
向量库	ChromaDB	文档向量持久化与语义检索
Embedding	BAAI/bge-small-zh-v1.5	中文文本向量化
会话记忆	SQLite + AsyncSqliteSaver	多会话状态持久化
语音识别	FunASR Paraformer	中文语音转文字
语音合成	GPT-SoVITS	日语角色音色输出
通信	SSE + WebSocket	流式文本、工具事件与语音通道

7. 已实现功能

7.1 角色化自然对话

- Amadeus 人格提示词和自然短句风格
- 普通对话与世界线长回答分离
- 自动换行和 Markdown 装饰清理
- DeepSeek / Qwen 提供商切换
- 多轮会话和用户画像提取

7.2 Agent 工具系统

工具	能力
<code>get_current_time</code>	获取真实时间与日期
<code>calculate</code>	数学计算
<code>create_reminder</code>	创建提醒
<code>send_email</code>	发送邮件
<code>search_knowledge_base</code>	检索知识库
<code>add_to_knowledge_base</code>	写入长期知识
<code>delete_from_knowledge_base</code>	安全删除知识
<code>search_web</code>	搜索最新信息
<code>fetch_text_from_url</code>	读取网页正文

工具调用通过 SSE 显示开始、完成和异常状态，用户可以看到 Agent 正在使用什么能力。

7.3 新版前端工作台

页面已由早期单一聊天界面升级为三栏工作台：

- 左侧：知识库上传、文件列表、删除和 RAG 问答。
- 中部：角色舞台、状态反馈和主要对话区。
- 右侧：运行状态、会话计数、工具计数和知识片段统计。
- 底部：世界线开关、观测/沉浸分段控件、语音与快捷操作。
- 移动端：保留响应式布局和可用的核心交互。



图 1：当前三栏工作台 - 知识库、角色舞台、对话控制台与系统监视器

7.4 语音与角色状态

系统已接入 FunASR 中文语音识别与 GPT-SoVITS 日语角色语音。角色控制器统一管理 `idle`、`thinking`、`tool`、`listening`、`speaking`、`error` 状态，并让立绘光效与音频电平联动。

当前渲染器为静态立绘，但 `CharacterStage` 已通过 `renderer`、`model-id`、状态和音频电平建立渲染器中立接口。后续接入 Live2D 时可以替换角色渲染层，不需要重写聊天、RAG 和状态逻辑。

7.5 稳定性与可维护性

- 修复被中断工具调用导致的 LangGraph 无效历史。
- 将 SSE 文本封装为 JSON，保留模型自然换行。
- 后端退出时主动关闭 SQLite 连接和 STT 工作进程。
- 日常启动取消 Uvicorn `--reload`，避免 Windows 残留父子进程。
- 新增 `stop_amadeus.bat`，按项目端口结束完整进程树。
- 当前自动化验证：后端 12 项测试、前端 22 项测试。

8. 当前完成度

功能	状态
角色聊天与 SSE 流式输出	已完成
DeepSeek / Qwen 模型切换	已完成
LangGraph ReAct Agent	已完成
9 类工具调用与可视化	已完成
文件上传、MD5 去重、删除	已完成
ChromaDB 语义检索	已完成
标准 RAG 与来源返回	已完成
世界线观测模式	已完成
世界线沉浸模式	已完成
示例世界线知识集	已完成
SQLite 多轮记忆	已完成
中断会话自动修复	已完成
FunASR 语音输入	已接入，依赖本地模型环境
GPT-SoVITS 语音输出	已接入，依赖本地模型与显卡
新版三栏工作台	已完成
Live2D 渲染接口	已预留，模型接入待实现
一键完整停止	已完成
一键完整启动	待实现
用户系统与多租户	待实现
Docker / 云部署	待实现

9. 启动与停止

9.1 后端

```
cd D:/amadeus  
D:/miniconda3/python.exe -m uvicorn backend.app.main:app --port 8000
```

日常运行不使用 `--reload`。热重载只用于明确需要自动重载代码的开发场景。

9.2 前端

```
cd D:/amadeus/frontend  
npm run dev
```

浏览器访问：`http://localhost:5173`

9.3 语音服务（可选）

```
D:/conda_envs/sovits/python.exe D:/amadeus/start_sovits_api.py
```

9.4 完全停止

双击项目根目录的 `stop_amadeus.bat`。脚本会结束占用 `5173`、`8000`、`9880` 的项目进程树。

10. 项目特色与答辩亮点

1. **不是普通聊天机器人**：Agent 能自主使用工具并展示执行过程。
2. **不是普通文件问答**：RAG 被用于世界线基线、人物约束和分歧点证据。
3. **双模式推演**：同一份资料既能做理性因果分析，也能做沉浸式叙事。
4. **支持原创人物世界线**：用户可以自建人物历史，而不局限于公开历史或动漫 IP。
5. **角色状态与业务解耦**：静态立绘可以逐步替换为 Live2D。
6. **有完整工程链路**：前端、API、向量库、会话记忆、语音和退出清理均已形成闭环。
7. **可解释性较强**：展示工具调用、知识文件、来源和资料缺口，而非只给结论。

11. 商业化落地方向

11.1 世界线创作与 IP 互动

面向动漫、游戏、小说和虚拟角色，提供“选择一个分歧点并继续世界”的互动体验。商业版本需要使用原创角色或获得 IP、立绘与声线授权。

11.2 教学型反事实实验室

面向历史、科学史、社会学和写作课程，让学生上传资料、设置变量并比较不同因果链。教师可以检查引用、假设和推演依据。

11.3 个人成长路径沙盘

用户录入个人经历、目标、资源和限制，比较“继续当前选择”与“采取另一方案”的可能路径。产品必须明确这是辅助思考而非确定性预测。

11.4 企业情景推演助手

将企业制度、产品资料、市场事件和业务约束写入私有知识库，用于新品策略、危机预案和运营情景讨论。需要补充权限、审计、多租户和数据隔离。

11.5 可售卖能力

- 世界线主题知识包
- 原创角色与 Live2D 形象包
- 私有知识库空间
- 团队协作与推演报告导出
- 高级模型、语音和长上下文配额
- 私有化部署与企业定制

12. 后续开发目标

阶段一：可稳定演示

- 完成一键启动和服务状态检查
- 增加模型连接测试、日志面板和错误指引
- 为世界线结果增加引用片段和导出功能
- 建立固定评测问题，比较无 RAG、RAG 和双模式效果
- 完成 Live2D 模型加载、口型同步和动作映射

阶段二：可持续使用

- 世界线节点图和分支历史回溯
- 多知识库与主题空间
- 会话、知识文件和推演项目管理
- 语音延迟优化与模型降级策略
- Windows 安装包或 Docker Compose

阶段三：可商业交付

- 登录、权限、配额、计费和多租户隔离
- 内容安全、审计日志、备份与恢复
- 原创角色资产和商业授权体系
- 云端部署、监控告警和 SLA
- 面向教育、创作或企业场景选择一个垂直方向做付费闭环

13. 总结

Amadeus 已从早期角色聊天 Demo 演进为一个具有明确主题的世界线推演产品原型。它用 RAG 保存“原本发生了什么”，用 Agent 决定“需要查什么、调用什么”，再通过观测或沉浸模式回答“如果改变一个节点，世界可能如何继续”。

当前版本已经具备答辩演示所需的完整主链路：

上传世界线资料
→ 设置分歧点
→ Agent 检索证据
→ 观测分析或沉浸叙事
→ 展示工具过程与角色反馈

下一阶段最重要的目标不是继续堆功能，而是完成一键启动、Live2D、推演结果引用与评测体系，并选择教育、互动创作或企业情景推演中的一个场景做深，形成可长期使用和可商业交付的产品。